

2025 年 12 月 8 日至 12 月 14 日周报

何瑞杰
中山大学, 大湾区大学

目录

1. 项目进展	2
1.1. 使用神经网络学习生命游戏的演化动力学	2
2. 文献阅读	3
2.1. Demoising Diffusion Implicit Models [1]	3
3. 下周计划	5
参考文献	6

速览

论文方面，本周阅读了 DDPM 后的经典工作 DDIM 的理论部分，DDIM 将 DDPM 中的 Markov 模型扩展为增广的 Markov 过程或是 x_0 条件下的一族 Markov 过程，并利用这一改变带来的性质同时达到兼容 DDPM 的训练成果和加速生成的目的。

项目方面，本周对先前搭建的简易规则推断进行了测试，在测试的 6 个规则中有五个规则预测正确。

其他自主学习方面，阅读了《非线性动力学与混沌》的第三章的部分内容，观看学习了《测度论》简易教程，了解了 σ -代数、测度、测度空间、Lebesgue 测度的定义。

1. 项目进展

1.1. 使用神经网络学习生命游戏的演化动力学

本周对先前搭建的简易规则推断进行了测试，在测试的 6 个规则中有五个规则预测正确。但由于目前的代码位于另一台机器中，无法获取，将在下周完善可视化的工作。

本周的规划工作重心为向 Overleaf 在线文章中同步至今的所有结果。

2. 文献阅读

2.1. Demoising Diffusion Implicit Models [1]

[ICLR 2021](#) | Jiaming Song et al.

在 DDPM 论文中，加噪过程为一个 Markov 过程，有状态转移分布 $p(\mathbf{x}_t|\mathbf{x}_{t-1})$ 和对应的反向转移分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 。这代表加噪过程中进行的步数和模型参与的去噪步骤数是相同的。另外，在假设状态转移分布为 Gauss 分布时，到达加噪过程终点时的分布 \mathbf{x}_N 的分布理论上趋于标准正态分布 $N(0, I)$ ，当 N 较小时， \mathbf{x}_N 的分布与标准正态分布不再近似，而去噪过程又是从标准正态分布 $N(0, I)$ 开始的，这就造成分布不对应。

本文为解决这一问题引入了成为隐式去噪扩散模型（denoising diffusion implicit models）。对于第一个问题，DDIM 引入了一个增广 Markov 加噪和去噪过程，使得生成过程中可以跳步，同时也一定程度缓解了第二个问题：在加噪过程中可以引入任意大的加噪步数，使得 \mathbf{x}_N 的分布趋于标准正态分布。除此之外，DDIM 还将噪声项趋于零，这表示加噪和去噪动力学从 SDE 变成了 ODE，从而获取更高的求解速度和更优的数值性能。

2.1.1. 增广 Markov 前向过程

DDIM 引入的去噪过程的转移分布为 $p(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ ，并令其为一个简单的 Gauss 分布 $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = N(\boldsymbol{\mu}(\mathbf{x}_t, \mathbf{x}_0), \sigma_t^2 \mathbf{I})$ 。由重参数化技巧， \mathbf{x}_{t-1} 可以写为

$$\begin{aligned} \mathbf{x}_{t-1} &\sim \boldsymbol{\mu}(\mathbf{x}_t, \mathbf{x}_0) + \sigma_t^2 \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \mathbf{I}) \\ &\sim a\mathbf{x}_t + b\mathbf{x}_0 + \sigma_t^2 \boldsymbol{\varepsilon} \end{aligned} \tag{1}$$

其中 a 和 b 是实数。DDIM 引入的来自 DDPM 的假设为 $\mathbf{x}_t \sim N(\sqrt{\alpha_t} \mathbf{x}_0, (1 - \alpha_t) \mathbf{I})$ ，因此用重参数化的语言来写，就是

$$\begin{aligned} \sqrt{\alpha_{t-1}} \mathbf{x}_0 + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\varepsilon} &\sim a(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \boldsymbol{\varepsilon}') + b\mathbf{x}_0 + \sigma_t \boldsymbol{\varepsilon}'' \\ N(\sqrt{\alpha_{t-1}} \mathbf{x}_0, (1 - \alpha_{t-1}) \mathbf{I}) &= N(a\sqrt{\alpha_t} \mathbf{x}_0 + b\mathbf{x}_0, (a^2(1 - \alpha_t) + \sigma_t^2) \mathbf{I}) \end{aligned} \tag{2}$$

分布参数对应相等，就得到

$$\begin{aligned} a &= \sqrt{\frac{1 - \alpha_{t-1} - \sigma_t^2}{1 - \alpha_t}} \\ b &= \sqrt{\alpha_{t-1}} - \sqrt{\alpha_t} \cdot \sqrt{\frac{1 - \alpha_{t-1} - \sigma_t^2}{1 - \alpha_t}} \end{aligned} \tag{3}$$

这样就得到逆向过程转移概率应该有的形式：

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = N\left(\sqrt{\alpha_{t-1}} \mathbf{x}_0 + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0}{\sqrt{1 - \alpha_t}}, \sigma_t^2 \mathbf{I}\right) \tag{4}$$

对应的加噪过程可以由 Bayes 公式给出

$$q_\sigma(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) = \frac{q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)q_\sigma(\mathbf{x}_t|\mathbf{x}_0)}{q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_0)} \tag{5}$$

然而事实上，由于上面推导中的 $t-1$ 时间步和 t 时间步并没有联系，我们可以将两个时间步视作 s, t ，满足 $0 < s < t$ ，这样一来跳步的去噪过程可以写成

$$q(\mathbf{x}_s | \mathbf{x}_t, \mathbf{x}_0) = N\left(\sqrt{\alpha_s} \mathbf{x}_0 + \sqrt{1 - \alpha_s - \sigma_{s,t}^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0}{\sqrt{1 - \alpha_t}}, \sigma_{s,t}^2 \mathbf{I}\right) \quad (6)$$

此时 $\sigma_{s,t}$ 需要做相应的调整。或者将 t 和 $t-1$ 的下标视作序列 $\{t\}_{t=0}^N$ 的一个子列 $\{t_k\}_{k=1}^N$, 相应地方差的下标就变成 σ_{t_k} 。

然而需要注意的是, 对 $q_\sigma(\mathbf{x}_{1:T} | \mathbf{x}_0)$ 的拆解依然使用了 Markov 性:

$$q_\sigma(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{k=1}^T q_\sigma(\mathbf{x}_k | \mathbf{x}_{1:k-1}, \mathbf{x}_0) = \prod_{k=1}^T q_\sigma(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{x}_0) \quad (7)$$

因此与其说 DDIM 使用了非 Markov 链的加噪/去噪模型, 不如说它使用的是一个相比原版**增广 (augmented) 的 Markov 链**, 其中状态 \hat{x}_t 可理解为 $(\mathbf{x}_t, \mathbf{x}_0)$ 。

2.1.2. 兼容 DDPM

注意 DDPM 中的目标可以写成

$$L_\gamma(\varepsilon_\theta) = \sum_{t=1}^T \gamma_t \mathbb{E}_* \left\| \varepsilon_\theta^{(t)} \left(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \varepsilon_t \right) - \varepsilon_t \right\|_2^2 \quad (8)$$

其目标所对齐或模拟的是 $q_\sigma(\mathbf{x}_0 | \mathbf{x}_t)$ 。我们假设通过 DDPM 训练目标训练好的模型 ε_θ^t 给出的是 \mathbf{x}_0 的一个估计。就可以利用该估计计算逆向转移概率。令

$$f_\theta^{(t)}(\mathbf{x}_t) = \frac{\mathbf{x}_t - \sqrt{1 - \alpha_t} \varepsilon_\theta^{(t)}(\mathbf{x}_t)}{\sqrt{\alpha_t}} \quad (9)$$

则逆向转移概率可以写成 $p_{\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} = q_\sigma(\mathbf{x}_{t-1} | \mathbf{x}_t, f_\theta^{(t)}(\mathbf{x}_t))$ 。自然地, 我们需要对齐模型估计的去噪序列和真实的序列:

$$J_\sigma(\varepsilon_\theta) = \mathbb{E}_{\mathbf{x}_{0:T} \sim q_\sigma(\mathbf{x}_{0:T})} [\log q_\sigma(\mathbf{x}_{1:T} | \mathbf{x}_0) - \log p_\theta(\mathbf{x}_{0:T})] \quad (10)$$

可以证明, 该目标与 DDPM 的目标等价。

在生成时, 给定 \mathbf{x}_t , 可以根据下式预测 \mathbf{x}_s

$$\mathbf{x}_s = \underbrace{\sqrt{\alpha_s} \left[\frac{\mathbf{x}_t - \sqrt{1 - \alpha_t} \varepsilon_\theta^{(t)}(\mathbf{x}_t)}{\sqrt{\alpha_t}} \right]}_{\mathbf{x}_0 \text{ 的预测值}} + \underbrace{\sqrt{1 - \alpha_s - \sigma_{s,t}^2} \varepsilon_\theta^{(t)}(\mathbf{x}_t) + \sigma_{s,t} \varepsilon_{s,t}}_{\text{指向 } \mathbf{x}_{t-1} \text{ 的调节项}} \quad (11)$$

如果对任意 s, t , 都令 $\sigma_{s,t} \rightarrow 0$, 则去噪动力学的随机性逐渐消失, 该离散动力学变成了下面的 ODE 的 Euler 离散化版本

$$d\bar{\mathbf{x}} = \varepsilon_\theta^{(t)} \left[\frac{\bar{\mathbf{x}}}{\sqrt{\sigma^2 + 1}} \right] d\sigma, \quad (12)$$

这还对应着 Song 等人 [2]论文中的 VE-SDE 的概率流 ODE 的形式。由于其没有随机性, 可以应用更快速的 ODE 数值解法。

为更好理解论文的理论, 本文需要参照 DDPM 和 DDIM 的代码。

3. 下周计划

论文阅读

1. 生成模型
 - DiT
2. 机器学习理论
 - Reconciling modern machine learning practice and the bias-variance trade-off

项目进度

1. 使用神经网络学习生命游戏的演化动力学
 - 更新在线 Overleaf 文档

理论学习

1. 随机过程课程
 - 开始总复习
2. 随机微分方程
 - 第五章完成
3. 非线性动力学与混沌
 - 第三章、第四章
4. Stein 实分析
 - 第一章
5. Sakurai 现代量子力学
 - 第一章

参考文献

- [1] J. Song, C. Meng, and S. Ermon, “Denoising Diffusion Implicit Models,” *CoRR*, 2020, [Online]. Available: <https://arxiv.org/abs/2010.02502>
- [2] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, “Score-Based Generative Modeling through Stochastic Differential Equations,” *CoRR*, 2020, [Online]. Available: <https://arxiv.org/abs/2011.13456>